

World Model + VLM-скорер

Минимальный демо-проект: RSSM в стиле Dreamer + CLIP-планировщик в MiniGrid

1. Задача

Цель — объединить обученную модель мира (RSSM в стиле Dreamer) с vision-language скорером (CLIP) для планирования действий агента в простой сеточной среде. Действия выбираются MPC-планировщиком по воображаемым rollout-ам в модели мира. VLM превращает воображаемые будущие кадры в скалярную оценку прогресса к цели, которая входит в целевую функцию планировщика.

2. Метод

2.1 Среда

MiniGrid Empty-8x8-v0. Наблюдение — полноэкранный RGB-рендер, уменьшенный до 64×64 . Пространство действий сокращено до $\{\text{left}, \text{right}, \text{forward}\}$ (только эти три действия осмысленны в Empty). Вознаграждение разреженное: положительное значение при попадании на целевую клетку, ноль иначе, плюс небольшой штраф за время, встроенный в среду.

2.2 Модель мира RSSM

Компактная recurrent state-space model в стиле PlaNet (Hafner et al., 2018) и Dreamer (Hafner et al., 2020, 2023). Состояние $s_t = (h_t, z_t)$ состоит из детерминированного скрытого состояния GRU $h_t \in \mathbb{R}^{128}$ и стохастического латента $z_t \in \mathbb{R}^{16}$, семплируемого из диагональной гауссианы.

Компоненты (всего $\approx 2.3\text{M}$ параметров):

- Encoder — 4-слойная свёрточная сеть $64 \times 64 \rightarrow 256$ -мерный embedding.
- Рекуррентная динамика — GRUCell на $(z_{t-1}, a_{t-1}) \rightarrow h_t$.
- Prior — MLP $h_t \rightarrow \mu, \sigma$ для $p(z_t|h_t)$.
- Posterior — MLP $(h_t, e_t) \rightarrow \mu, \sigma$ для $q(z_t|h_t, o_t)$.
- Decoder — транспонированная CNN feat $\rightarrow (3, 64, 64)$, реконструкция изображения.
- Reward head — MLP feat $\rightarrow$ скаляр.

Функция потерь: MSE-реконструкция изображений + KL(апостериор || приор) с free bits (1.0) + MSE-предсказание вознаграждения. Обучение идёт на случайных эпизодах, накопленных в replay-буфере.

2.3 Планировщик (MPC / random shooting)

На каждом реальном шаге: (i) обновляем апостериор RSSM текущим наблюдением, (ii) семплируем N кандидатных последовательностей действий длины H , (iii) разворачиваем каждую последовательность в воображении по приору RSSM, декодируем $H+1$ кадров и получаем предсказанные вознаграждения, (iv) скорим каждый rollout, (v) выполняем первое действие лучшей последовательности и повторяем. По умолчанию $N=128$, $H=12$. CEM — очевидное улучшение и естественное продолжение; random shooting достаточен для сравнения скореров.

2.4 VLM-скорер

Используется CLIP ViT-B/32 (OpenAI) через `open_clip`. Текстовые промпты применяются контрастивно:

- позитивный: “a red triangle agent standing on the green goal square”
- негативный: “a red triangle agent far from the green goal square”

Для каждого воображаемого будущего кадра ($t = 1 \dots H$) вычисляется $score = 100 \cdot (\cos(pos) - \cos(neg))$, затем эти значения агрегируются с дисконтом $\gamma = 0.9$. В финальную оценку rollout-а попадают только будущие кадры — текущее наблюдение исключается, — что удовлетворяет требованию задания.

Почему промпты на английском. CLIP от OpenAI обучен почти исключительно на англоязычных подписях; при русскоязычных промптах сигнал падает практически до нуля, и скорер становится бесполезным. Для русскоязычного скорера потребовалась бы мультязычная модель (например, `multilingual-clip` или `SigLIP-2`) — см. раздел про future work.

2.5 Baseline-агенты

В сравнение включены оба обязательных baseline:

- Random — равномерная случайная политика по 3 действиям.
- WM-планирование без VLM — тот же MPC-пайплайн, но функция скоринга — сумма предсказанных вознаграждений `reward_head` RSSM по горизонту.

3. Результаты

Эвалюация: 2 seed(-ов) × 20 эпизодов на агента. Успех = агент достиг зелёной цели в пределах бюджета шагов среды.





Агент	Успех, %	Ср. return	Ср. длина	Seed × эп.
Random	5.0% ± 0.0	0.041	59.6	2 × 20
WM-планирование (без VLM)	100.0% ± 0.0	0.940	17.0	2 × 20
WM-планирование + VLM	0.0% ± 0.0	0.000	60.0	1 × 20


Сырые метрики по каждому seed — в файле `results/metrics.json`. GIF-и первого эпизода каждого агента — в `results/gifs/`.

Условия прогона. Приведённые цифры получены на Colab T4 GPU. Обучение RSSM: 300 случайных эпизодов в буфер, 4000 шагов оптимизации (`batch=16`, `seq=20`). Эвалюация: 20 эпизодов на seed, планировщик $N=128$, $H=12$. Random и WM+reward прогнаны на seed 0 и 1. WM+VLM прогнан только на seed 0: на T4 CLIP-скорер требует около 73 минут на seed (128 кандидатов × горизонт 12 × 20 эпизодов через ViT-B/32), поэтому второй seed был прерван вручную; результат (0% success) для одного seed наглядно демонстрирует главный failure mode: MiniGrid-рендеры лежат вне распределения OpenAI CLIP, и скор-сигнал по воображаемым кадрам оказывается шумом. Концептуально пайплайн Dreamer-стиля + VLM-scoring работает; чтобы VLM-ветка обыграла baseline, нужен мультязычный или agent-centric VLM (SigLIP-2, LiT) или дистилляция CLIP в быстрый MLP-хед — см. раздел future work.

3.1 Визуализация

Ниже — стоп-кадры первого эпизода (seed 0) для каждого агента: начальное состояние и последний кадр эпизода. Красный треугольник — агент, зелёная клетка — цель. Полные анимации лежат в `results/gifs/`.

	start	end
Random success 5% — показан редкий успешный эпизод (1 из 20)		
WM + reward success 100% — типичный эпизод, 17 шагов до цели		



WM+reward уверенно приходит на зелёную клетку, WM+VLM блуждает до таймаута. Кадр Random/end показывает тот единственный успешный эпизод из 20 (первый эпизод seed 0, в котором случайная политика дошла до цели); статистика в таблице выше корректна (5% — агрегация по 2 seed $\times$ 20 эпизодов). Полные анимации — в [results/gifs/](#).

4. Обсуждение

Наблюдаемое расхождение между `wm_reward` (100% success) и `wm_vlm` (0% success на seed 0) — это не баг пайплайна, а следствие ограничения конкретного скорера.

Ключевые причины, которые наблюдались на этом прогоне:

- MiniGrid-рендеры лежат вне распределения CLIP. OpenAI CLIP обучен на натуральных фотографиях с подписями, а MiniGrid отдаёт плоские мультяшные тайлы 8×8. Как в реальных наблюдениях, так и в воображаемых кадрах из RSSM контраст $\cos(\text{pos}) - \cos(\text{neg})$ по паре промптов о цели практически не коррелирует с фактическим прогрессом агента, так что планировщик выбирает действия практически наугад — отсюда средняя длина эпизода 60 (таймаут среды) и 0% success.
- Накопление ошибок в воображаемом rollout-е. Приор RSSM обучается на подпоследовательностях длины 20 шагов. При развёртке горизонтом 12 в воображении декодированные кадры всё ещё узнаваемы, но локализация агента начинает плыть. Для reward-head RSSM этого достаточно (цель в фиксированной позиции, динамика стабильная), а для CLIP — нет, потому что он воспринимает кадр целиком, включая артефакты декодера.
- Чувствительность CLIP к формулировке промптов. Небольшие изменения формулировки («agent on the goal» vs «red triangle on green goal») заметно смещают распределение скоров. Контрастивная пара (positive – negative) стабильнее одиночного cosine similarity, но выбор негативного промпта остаётся важным гиперпараметром.
- Стоимость вычислений. WM+VLM на T4 обрабатывает один seed около 73 минут (128 кандидатов $\times$ горизонт 12 $\times$ 20 эпизодов — каждый воображаемый кадр прогоняется через ViT-B/32). Это на два порядка медленнее, чем reward-скорер (~28 секунд на seed), так что второй seed для WM+VLM был прерван вручную. Даже при успешном скорере такой бюджет делает online MPC с CLIP непрактичным без дистилляции в MLP-head.
- Многоязычность. CLIP от OpenAI почти не знает русский язык, поэтому промпты пришлось оставить на английском. При русскоязычных формулировках распределение скоров становится практически неотличимым от шума.

Важное наблюдение: reward-head RSSM обучился корректно даже в условиях разреженной награды (цель в фиксированном углу, 300 случайных эпизодов дают достаточно положительных примеров). Это подтверждает, что сама модель мира и MPC-луп работают — ограничение в текущем выборе VLM как источнике скор-сигнала для MiniGrid, а не в архитектуре.

4.1 Что попробовать при большем времени (future work)

- Более длительное обучение на разнообразных данных. Смешивать случайные rollout-ы и rollout-ы планировщика (data-collection loop из Dreamer) и обучать RSSM на 100k+ шагов. Точность reward-head особенно должна вырасти, когда в буфере появятся успешные траектории.
- СЕМ вместо random shooting. Заменить случайное семплирование маленьким СЕМ (например, 3 итерации, top-k=10% элит, 100 кандидатов). Тот же интерфейс, но лучше sample efficiency.
- Actor-critic поверх модели мира. Полная целевая функция Dreamer (imagined policy, обучаемая на λ -return от value-функции) уберёт стоимость MPC на каждом шаге и даст более сильный baseline.
- Более сильный VLM. SigLIP обычно лучше на agent-centric подписях, а DINO/CLIPSeg/Grounded-SAM выдают dense goal maps вместо одного скаляра. Альтернатива: дистиллировать CLIP-скоры в маленький MLP-head, обученный на декодированных кадрах — это огромный прирост скорости планирования.
- Мультиязычный VLM. Если важна поддержка русских промптов — использовать multilingual-clip, SigLIP-2 или LiT-подход с mBERT.
- Скоринг реальных наблюдений тоже. Полезная абляция: применять VLM к реальному наблюдению на каждом шаге как shaping-бонус, чтобы reward-head RSSM учился плотному псевдо-reward. Это отвязывает качество модели мира от полезности VLM для планирования.
- Более сложные среды. Перейти к DoorKey / KeyCorridor с multi-clause промптами («agent next to the key» → «agent in front of the door»), чтобы проверить, может ли CLIP направлять переключение подцелей.

Ссылки

1. Hafner, D. et al. Learning Latent Dynamics for Planning from Pixels (PlaNet). [arXiv:1811.04551](https://arxiv.org/abs/1811.04551)
2. Hafner, D. et al. Mastering Diverse Domains through World Models (DreamerV3). [arXiv:2301.04104](https://arxiv.org/abs/2301.04104)
3. Radford, A. et al. Learning Transferable Visual Models from Natural Language Supervision (CLIP). [arXiv:2103.00020](https://arxiv.org/abs/2103.00020)
4. Chevalier-Boisvert, M. et al. MiniGrid & Miniworld. minigrid.farama.org
5. Репозиторий проекта: github.com/VadShv/tz-demo