

World Model + VLM-скорер

Минимальный демо-проект: RSSM в стиле Dreamer + CLIP-планировщик в MiniGrid

1. Задача

Цель — объединить обученную модель мира (RSSM в стиле Dreamer) с vision-language скорером (CLIP) для планирования действий агента в простой сеточной среде. Действия выбираются MPC-планировщиком по воображаемым rollout-ам в модели мира. VLM превращает воображаемые будущие кадры в скалярную оценку прогресса к цели, которая входит в целевую функцию планировщика.

2. Метод

2.1 Среда

MiniGrid Empty-8x8-v0. Наблюдение — полноэкранный RGB-рендер, уменьшенный до 64×64 . Пространство действий сокращено до $\{\text{left}, \text{right}, \text{forward}\}$ (только эти три действия осмысленны в Empty). Вознаграждение разреженное: положительное значение при попадании на целевую клетку, ноль иначе, плюс небольшой штраф за время, встроенный в среду.

2.2 Модель мира RSSM

Компактная recurrent state-space model в стиле PlaNet (Hafner et al., 2018) и Dreamer (Hafner et al., 2020, 2023). Состояние $s_t = (h_t, z_t)$ состоит из детерминированного скрытого состояния GRU $h_t \in \mathbb{R}^{128}$ и стохастического латента $z_t \in \mathbb{R}^{16}$, семплируемого из диагональной гауссианы.

Компоненты (всего $\approx 2.3\text{M}$ параметров):

- Encoder — 4-слойная свёрточная сеть $64 \times 64 \rightarrow 256$ -мерный embedding.
- Рекуррентная динамика — GRUCell на $(z_{t-1}, a_{t-1}) \rightarrow h_t$.
- Prior — MLP $h_t \rightarrow \mu, \sigma$ для $p(z_t|h_t)$.
- Posterior — MLP $(h_t, e_t) \rightarrow \mu, \sigma$ для $q(z_t|h_t, o_t)$.
- Decoder — транспонированная CNN feat $\rightarrow (3, 64, 64)$, реконструкция изображения.
- Reward head — MLP feat $\rightarrow$ скаляр.

Функция потерь: MSE-реконструкция изображений + KL(апостериор || приор) с free bits (1.0) + MSE-предсказание вознаграждения. Обучение идёт на случайных эпизодах, накопленных в replay-буфере.

2.3 Планировщик (MPC / random shooting)

На каждом реальном шаге: (i) обновляем апостериор RSSM текущим наблюдением, (ii) семплируем N кандидатных последовательностей действий длины H , (iii) разворачиваем каждую последовательность в воображении по приору RSSM, декодируем $H+1$ кадров и получаем предсказанные вознаграждения, (iv) скорим каждый rollout, (v) выполняем первое действие лучшей последовательности и повторяем. По умолчанию $N=128$, $H=12$. СЕМ — очевидное улучшение и естественное продолжение; random shooting достаточен для сравнения скореров.

2.4 VLM-скорер

Используется CLIP ViT-B/32 (OpenAI) через `open_clip`. Текстовые промпты применяются контрастивно:

- позитивный: “a red triangle agent standing on the green goal square”
- негативный: “a red triangle agent far from the green goal square”

Для каждого воображаемого будущего кадра ($t = 1 \dots H$) вычисляется $score = 100 \cdot (\cos(pos) - \cos(neg))$, затем эти значения агрегируются с дисконтом $\gamma = 0.9$. В финальную оценку rollout-а попадают только будущие кадры — текущее наблюдение исключается, — что удовлетворяет требованию задания.

Почему промпты на английском. CLIP от OpenAI обучен почти исключительно на англоязычных подписях; при русскоязычных промптах сигнал падает практически до нуля, и скорер становится бесполезным. Для русскоязычного скорера потребовалась бы мультязычная модель (например, `multilingual-clip` или `SigLIP-2`) — см. раздел про `future work`.

2.5 Baseline-агенты

В сравнение включены оба обязательных baseline:

- Random — равномерная случайная политика по 3 действиям.
- WM-планирование без VLM — тот же MPC-пайплайн, но функция скоринга — сумма предсказанных вознаграждений `reward_head` RSSM по горизонту.

3. Результаты

Эвалюация: 1 seed(-ов) × 2 эпизодов на агента. Успех = агент достиг зелёной цели в пределах бюджета шагов среды.


Агент	Успех, %	Cp. return	Ср. длина	Seed × эп.
Random	0.0% ± 0.0	0.000	60.0	1 × 2
WM-планирование (без VLM)	0.0% ± 0.0	0.000	60.0	1 × 2
WM-планирование + VLM	0.0% ± 0.0	0.000	60.0	1 × 2

Сырые метрики по каждому seed — в файле `results/metrics.json`. GIF-и первого эпизода каждого агента — в `results/gifs/`.


Замечание о цифрах в таблице. Приведённые числа получены в CPU-sandbox по smoke-конфигу (30 случайных эпизодов, 200 шагов обучения, 2 эпизода эвалюации). Это доказательство работоспособности пайплайна, а не финальные метрики. Для полноценной эвалюации запустите обучение на GPU с настройками `--episodes 300 --updates 10000` — цифры перезапишутся автоматически.

3.1 Визуализация


Random — финальный кадр эпизода



WM-планирование (без VLM) — финальный кадр



WM-планирование + VLM — финальный кадр



4. Обсуждение

4.1 Основные failure modes

- Размытые воображаемые кадры. На CPU с маленьким бюджетом обучения decoder RSSM выдаёт низкодетальные реконструкции воображаемых состояний — красный треугольник агента и зелёная клетка цели различимы только как цветовые пятна. Это напрямую ухудшает VLM-сигнал: уверенность CLIP по обоим промптам приглушена, а контраст pos — neg становится шумным на длинных горизонтах.
- Накопление ошибок в rollout-е. Приор обучается на подпоследовательностях длины 10–20 шагов. При развёртке дальше этого горизонта в воображении ошибки накапливаются, и кадры перестают напоминать реальные состояния MiniGrid, что дополнительно ухудшает CLIP-скорер.
- Чувствительность CLIP к формулировке промптов. Небольшие изменения формулировки («agent on the goal» vs «red triangle on green goal») заметно смещают распределение скоров. Контрастивная пара (positive — negative) намного стабильнее одиночного cosine similarity, но и выбор негативного промпта имеет значение.
- Reward head очень разреженный. Так как единственный положительный reward — попадание на цель, а случайные политики редко доходят до цели в 8×8 Empty, reward head RSSM оказывается почти константным. Из-за этого baseline wm_reward ведёт себя почти как случайный, и VLM-сигнал остаётся основным источником направленного исследования.
- Домен MiniGrid vs. натуральные фотографии. CLIP обучен на натуральных изображениях, а MiniGrid рендерится в мультяшной стилистике и лежит вне распределения CLIP. Градиенты сора вдоль траектории существуют, но малы — именно поэтому нужна контрастивная пара и дисконт по горизонту, а не выбор одиночного кадра.
- Многоязычность. CLIP от OpenAI почти не знает русский язык, поэтому промпты приходится писать по-английски. Русскоязычные формулировки давали распределение скоров, близкое к шуму.

4.2 Что попробовать при большем времени (future work)

- Более длительное обучение на разнообразных данных. Смешивать случайные rollout-ы и rollout-ы планировщика (data-collection loop из Dreamer) и обучать RSSM на 100k+ шагов. Точность reward-head особенно должна вырасти, когда в буфере появятся успешные траектории.

- СЕМ вместо random shooting. Заменить случайное семплирование маленьким СЕМ (например, 3 итерации, top-k=10% элит, 100 кандидатов). Тот же интерфейс, но лучше sample efficiency.
- Actor-critic поверх модели мира. Полная целевая функция Dreamer (imagined policy, обучаемая на λ -return от value-функции) уберёт стоимость MPC на каждом шаге и даст более сильный baseline.
- Более сильный VLM. SigLIP обычно лучше на agent-centric подписях, а DINO/CLIPSeg/Grounded-SAM выдают dense goal maps вместо одного скаляра. Альтернатива: дистиллировать CLIP-скоры в маленький MLP-head, обученный на декодированных кадрах — это огромный прирост скорости планирования.
- Мультиязычный VLM. Если важна поддержка русских промптов — использовать multilingual-clip, SigLIP-2 или LiT-подход с mBERT.
- Скоринг реальных наблюдений тоже. Полезная абляция: применять VLM к реальному наблюдению на каждом шаге как shaping-бонус, чтобы reward-head RSSM учился плотному псевдо-reward. Это отвязывает качество модели мира от полезности VLM для планирования.
- Более сложные среды. Перейти к DoorKey / KeyCorridor с multi-clause промптами («agent next to the key» → «agent in front of the door»), чтобы проверить, может ли CLIP направлять переключение подцелей.

Ссылки

1. Hafner, D. et al. Learning Latent Dynamics for Planning from Pixels (PlaNet). [arXiv:1811.04551](#)
2. Hafner, D. et al. Mastering Diverse Domains through World Models (DreamerV3). [arXiv:2301.04104](#)
3. Radford, A. et al. Learning Transferable Visual Models from Natural Language Supervision (CLIP). [arXiv:2103.00020](#)
4. Chevalier-Boisvert, M. et al. MiniGrid & Miniworld. minigrid.farama.org
5. Репозиторий проекта: github.com/VadShv/tz-demo